

O Poder Das CNNs Em Aplicações de ML Envolvendo Identificação e Classificação de Imagens

Por: Dr. Arnaldo de Carvalho Junior

Data: 13/08/2024

1. O QUE É UMA CNN?

Uma rede neural convolucional (convolutional neural network – CNN) é um tipo especializado de algoritmo de aprendizado profundo (deep learning) projetado para processar e analisar dados visuais. É muito utilizada em aplicações de aprendizado de máquina (machine learning – ML) [1]. Inspirados no córtex visual humano, as CNNs usam operações de convolução para extrair recursos e identificar padrões dentro das imagens.




Figura 1 – Arquitetura de CNN
Fonte: Adaptado de [2].

A CNN é um tipo de rede neural do tipo “olhar para a frente” (feedforward neural network – FNN) que aprende uma característica por meio de otimização de filtros [1]. Essa arquitetura permite que as CNNs interpretem e classifiquem imagens com eficiência, tornando-as inestimáveis em aplicativos de visão computacional [2]. A Figura 1 apresenta uma arquitetura de uma CNN.

2. CAMADAS-CHAVE DA CNN

a) Camada convolucional (*convolutional layer*): este é o bloco de construção principal de uma CNN, onde os filtros (*kernels*) deslizam sobre a imagem de entrada para detectar recursos (*features*) como bordas, contrastes e texturas. A saída é um mapa de recursos que destaca esses recursos detectados. A Figura 2 apresenta as atividades da camada convolucional. Já a sequência de imagens da Figura 3 apresenta um exemplo do processo convolucional. Vários filtros de convolução podem ser aplicados, procurando-se extrair características específicas de um padrão 2D como contorno, contraste, objeto, etc [1].




Figura 2 – Série de Convoluções como Forma de Extração de Características da Imagem, pela CNN.

Fonte: Adaptado de [3].




Figura 3 -Sequência de Convolução.
Fonte: Adaptado de [4].

b) Camada de agrupamento (*pooling layer*): Após a camada convolucional, as camadas de agrupamento diminuem os mapas de recursos, reduzindo suas dimensões espaciais. Esta etapa diminui a complexidade computacional e ajuda a evitar o excesso de ajuste. O máximo de pool, que seleciona o valor máximo de uma região, é uma técnica comum usada aqui.

c) Camada de ativação da unidade retificadora linear (*rectified linear unit* – ReLU): A ReLU introduz a não linearidade no modelo, permitindo que ele aprenda padrões e relacionamentos complexos nos dados. A ReLU é uma das funções de ativação mais utilizadas atualmente em redes neurais pela sua rapidez no processo de aprendizagem [5]. Na função ReLU, se a entrada for negativa, ela será convertida em zero e o neurônio não será ativado. Isso significa que, ao mesmo tempo, apenas alguns neurônios são ativados, tornando a rede esparsa, eficiente e de computação fácil. Essa vantagem também pode ser considerada uma desvantagem, pois os neurônios utilizando ReLU tendem a “morrer” durante o treinamento, causando a saída do neurônio iniciar a produzir apenas zeros [6]. Para evitar isso, uma variação da ReLU, chamada *Leaky-ReLU* (LReLU) foi desenvolvida, que aplica uma ligeira inclinação na função de ativação para valores menores que zero [7]. A Figura 4 apresenta as funções de ativação ReLU e sua variante Leaky-ReLU [8].





Figura 4 – Funções de Ativação ReLU e Leaky-ReLU.
Fonte: Adaptado de [8].

d) Camada totalmente conectada (*fully connected layer*): Nos estágios finais, as camadas totalmente conectadas usam os recursos de alto nível aprendidos pelas camadas anteriores para fazer previsões. Cada neurônio nessas camadas está conectado a todos os neurônios da camada anterior, integrando todos os recursos extraídos para produzir a saída final.

3. CNN X ANN

Embora as redes neurais artificiais (*artificial neural networks* – ANNs) sejam versáteis [1], elas lutam com dados de alta dimensão, como imagens devido à sua natureza totalmente conectada. As CNNs, no entanto, são projetadas especificamente para lidar com estruturas de dados semelhantes à grade (*grid*) ou matriz, tornando-as altamente eficientes para o processamento de imagens. Sua capacidade de capturar hierarquias espaciais e padrões locais os diferencia das ANNs tradicionais.

3.1. A ANN NÃO SERVE PARA PROCESSAR IMAGENS?

As ANNs exigem engenharia extensa de recursos e lutam com a alta dimensionalidade dos dados da imagem. Por outro lado, as CNNs aprendem automaticamente representações hierárquicas de recursos, melhorando significativamente a precisão e reduzindo a necessidade de intervenção manual.

4. APLICAÇÕES DA CNN

As CNNs transformaram indústrias com sua alta precisão em tarefas relacionadas à imagem. Elas são amplamente utilizadas em:

- Análise de imagem médica: auxiliando no diagnóstico de doenças através do reconhecimento de imagem.
- Veículos autônomos: permitindo a detecção de objetos e o entendimento da cena.
- Reconhecimento facial: alimentando sistemas de segurança e autenticação.

Além das aplicações que envolvem imagens, existem pesquisas utilizando CNNs também em processamento de linguagem natural (*natural language processing* – NLP), interfaces cérebro-computador e séries temporais como financeiras, por exemplo [1].

5. CONCLUSÃO

A arquitetura de uma CNN é projetada para aproveitar a estrutura 2D de uma imagem de entrada. Outro benefício das CNNs é que elas são mais fáceis de treinar e possuem muito menos parâmetros do que redes totalmente conectadas com o mesmo número de unidades ocultas.

As CNNs continuam a ultrapassar os limites do que é possível na aprendizagem profunda, oferecendo soluções poderosas para desafios complexos de dados visuais.

6. REFERÊNCIAS

- [1] CARVALHO JUNIOR, A. Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML. EAILab Posts. 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%205%20-%20RNAs.pdf. Acessado em Ago 13, 2024.
- [2] VERMA, J. Convolutional Neural Networks, Machine Learning Community (Linkedin Group), 2024. Disponível em: https://media.licdn.com/dms/image/v2/D4D22AQHp54hbofrRjQ/feedshare-shrink_800/feedshare-shrink_800/0/1723566397982?e=1726704000&v=beta&t=pme9UxCdvRgXd3jNoGq1ETfuRRxVqUYpxY9P9h09Pb8. Acessado em Ago 13, 2024.
- [3] SUPERANNOTATE, Convolutional Neural Networks: 1998-2023 Overview, Super Annotate (Blog), 2023. Disponível em: <https://www.superannotate.com/blog/guide-to-convolutional-neural-networks>. Acessado em Ago 13, 2024.
- [4] SCIENTISTCAFE, 12.2 Convolutional Neural Network, Scientist Cafe (Blog), 2023. Disponível em: <https://scientistcafe.com/ids/convolutional-neural-network.html>. Acessado em Ago 13, 2024.
- [5] CARVALHO JUNIOR, A. Função de Ativação, o Núcleo da Composição de Neurônios Artificiais. EAILab Posts. 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%204%20-%20Função%20de%20Ativação.pdf. Acessado em Ago 13, 2024.
- [6] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. *et al.*, Rotary Inverted Pendulum Identification for Control by Paraconsistent Neural Network, in IEEE Access, 2021. DOI: 10.1109/ACCESS.2021.3080176.
- [7] CARVALHO, A., JUSTO, J.F., ANGELICO, B.A. *et al.* Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, Applied Soft Computing, 2022, 109927, ISSN 1568-4946. DOI: 10.1016/j.asoc.2022.109927.
- [8] LIU, D. A Practical Guide to ReLU. Medium, 2017. Disponível em: <https://medium.com/@danqing/a-practical-guide-to-relu-b83ca804f1f7>. Acessado em Ago 13, 2024.