

Melhores bibliotecas Python para aprendizado de máquina

Por: Prof. Dr. Arnaldo de Carvalho Junior

Data: Janeiro 20, 2025.

INTRODUÇÃO

A inteligência artificial (IA) (*artificial intelligence* – AI) é um vasto campo da ciência da computação que está revolucionando indústrias e melhorando a vida das pessoas. Como apresentado em *post* anterior [1], o termo IA é amplo e aplicado ao desenvolvimento de sistemas e processos capazes de raciocinar, classificar, descobrir significado, generalizar ou aprender com experiências passadas. A IA engloba uma série de algoritmos, ferramentas matemáticas e estatísticas e pode ser subdividida em camadas, conforme a Figura 1 [2].




Figura 1 – Subdivisões da Inteligência artificial.
Fonte: Adaptado de [2].

O aprendizado de máquinas (*machine learning* – ML) é um subconjunto focado em sistemas capazes de aprender com os dados. Técnicas como aprendizado supervisionado, aprendizado sem supervisão e árvores de decisão são os pilares deste campo [1]. Já o aprendizado de máquinas pequeno (TinyML) é uma tecnologia que possibilita a execução de modelos de ML serem executados em dispositivos de baixo consumo, como sensores, dispositivos vestíveis (*wearables*) e dispositivos inteligentes para IA das coisas (*artificial intelligence of things* - AIoT), trazendo benefícios para empresas, como maior autonomia, privacidade e eficiência. Além disso permite um tempo de resposta menor pois a tomada

de decisão pode ser realizada na borda do sistema, onde o dispositivo está instalado, em vez de ter que consultar um sistema decisório na nuvem [3].

As redes neurais artificiais (RNA) (*artificial neural networks* - ANNs) são técnicas computacionais que apresentam um modelo matemático inspirado em cérebros biológicos e que adquirem conhecimento através da experiência [1].

O aprendizado profundo (*deep learning* – DL) é um ramo especializado de RNAs que se aprofunda em dados complexos. Tecnologias como redes neurais recorrentes – (*recurrent neural networks* – RNN) para séries temporais de dados, redes neurais convolucionais (*convolutional neural networks* – CNNs) para classificação de imagens e algoritmos transformadores (*transformer*) para processamento de linguagem natural são exemplos de DL [1],[4].

Uma linguagem de programação que tem se destacado em projetos de ML e TinyML é o Python. Entre as principais razões destacam-se a sintaxe clara e expressiva, tornando a linguagem fácil de aprender e usar, a flexibilidade e um poderoso ecossistema de bibliotecas e *frameworks*. Isso permite que os projetistas de IA possam se concentrar mais no desenvolvimento da aplicação e da solução do que na elaboração maçante de códigos e algoritmos [5]. A Figura 2 apresenta as principais bibliotecas utilizadas para TinyML e ML.




Figura 2 – Principais Bibliotecas para ML e TinyML.
Fonte: O autor (2025).

PRINCIPAIS BIBLIOTECAS PARA TINYML

a) Tensorflow: Desenvolvido pelo Google, o TensorFlow é uma poderosa estrutura de código aberto para criar e implantar modelos de ML. É particularmente popular para tarefas de aprendizado profundo e suporta ambientes de produção escaláveis.

Site: <https://www.tensorflow.org>

Código fonte: <https://github.com/tensorflow/tensorflow>

b) Keras: É uma interface de programação de aplicações (*application programming interface* - API) de redes neurais de alto nível que funciona perfeitamente com o TensorFlow. Ele simplifica a criação de modelos complexos de aprendizado de máquina, como RNNs, CNNs e Transformers, com uma interface amigável.

Site: <https://keras.io>

Código fonte: <https://github.com/keras-team/keras>

c) Numpy: É a espinha dorsal da computação científica em Python. O Numpy fornece suporte a grandes matrizes e matrizes multidimensionais, junto com uma coleção de funções matemáticas para operar nessas matrizes.

Site: <https://numpy.org>

Código fonte: <https://github.com/numpy/numpy>

d) Pandas: Simplifica a manipulação e análise de dados, facilitando a limpeza e o pré-processamento de dados para tarefas de aprendizado de máquina.

Site: <https://pandas.pydata.org>

Código fonte: <https://github.com/pandas-dev/pandas>

e) Scikit-Learn: Biblioteca para o aprendizado de máquina, oferecendo ferramentas eficientes para pré-processamento, classificação, regressão, agrupamento e redução de dimensionalidade.

Site: <https://scikit-learn.org>

Código fonte: <https://github.com/scikit-learn/scikit-learn>

OUTRAS BIBLIOTECAS MUITO UTILIZADAS EM ML

Além das bibliotecas já citadas para TinyML, outras bibliotecas muito utilizadas em projetos de ML são:

a) Orange: É uma ferramenta de programação visual para visualização e análise de dados. É ideal para iniciantes no aprendizado de máquina, oferecendo uma interface interativa para criar modelos sem codificação extensa.

Site: <https://orange.biolab.si>

Código fonte: <https://github.com/biolab/orange3>

b) Matplotlib: Biblioteca fundamental para visualização de dados, o Matplotlib permite a criação de uma ampla gama de gráficos estáticos, animados e interativos para interpretar visualmente os conjuntos de dados.

Site: <https://matplotlib.org>

Código fonte: <https://github.com/matplotlib/matplotlib>

c) Seaborn: outra biblioteca Python de código aberto, baseado no Matplotlib, mas apresenta as estruturas de dados de Pandas. O SeaBorn é frequentemente usado em projetos de ML, pois pode gerar gráficos de dados de aprendizado. De todas as bibliotecas Python, produz os mais esteticamente agradáveis, tornando-o uma escolha eficaz se for utilizado também para marketing e análise de dados [6].

Site: <https://seaborn.pydata.org/>

Código fonte: <https://github.com/mwaskom/seaborn>

d) Pytorch: Mantida pela Meta (anteriormente Facebook), a Pytorch é conhecida por seu gráfico dinâmico de computação e facilidade de experimentação. É preferido na pesquisa e produção devido à sua flexibilidade e suporte nativo à aceleração da GPU.

Site: <https://pytorch.org>

Código fonte: <https://github.com/pytorch/pytorch>

e) Scipy: extensão do Numpy com funcionalidades adicionais para otimização, integração, interpolação e muito mais. É amplamente utilizado para tarefas científicas e de engenharia.

Site: <https://scipy.org>

Código fonte: <https://github.com/scipy/scipy>

PLATAFORMAS PARA ML E TINYML “NO-CODE”

Existem plataformas completas, que integram diferentes algoritmos e bibliotecas em uma *interface* amigável para o desenvolvimento de soluções de ML que podem ser embarcadas

em praticamente qualquer *hardware*, inclusive dispositivos TinyML. Essas plataformas são chamadas de “sem código” (“*no-code*”) pois permitem que o processo de construção, implantação e escalabilidade de aplicativos ML possam ser incorporados de forma rápida e fácil, mesmo por leigos em programação de IA.

a) Edge Impulse™: é uma plataforma de operações de aprendizado de máquina (*machine learning operations* - MLOPS) baseada em nuvem para o desenvolvimento de sistemas ML incorporados e de borda (TinyML) que podem ser implantados em uma ampla gama de *hardwares* alvo [7]. O Edge Impulse é um exemplo de plataforma *no-code* que permite carregar diferentes bases de dados, selecionar o modelo de IA, treinar, avaliar e exportar para diferentes microcontroladores, como ESP32, Raspberry e Nvidia. A Figura 3 apresenta o fluxo de trabalho da plataforma.

Edge Impulse: <https://edgeimpulse.com/>




Figura 3 – Fluxo de trabalho da plataforma Edge Impulse.

Fonte: O autor (2025).

b) Edge AI Labs: representa uma nova plataforma que fornece uma coleção de conjuntos de dados, plantas e modelos de IA com curadoria de nossos grupos de trabalho e contribuição da comunidade da Edge AI Foundation, anteriormente conhecida como a fundação TinyML. A Edge AI Foundation é lugar da inovação global, colaboração, advocacia e educação. O Edge AI Labs fornece diversos modelos de ML para plataforma Raspberry..

Edge AI Labs: <https://edgeai.modelnova.ai/>

Edge AI Foundation: <https://www.edgeaifoundation.org/>

REFERÊNCIAS

[1] CARVALHO JUNIOR, Arnaldo. Coletânea de Posts EAILAB 2023-2024. EAILAB, IFSP, 1º ed, 70p, 2024. Disponível em:

<https://github.com/EAILAB-IFSP/PUBLICATIONS/blob/main/POSTS%20EAILAB%20Vol%201%202024.pdf>. Acessado em Jan 17, 2025.

[2] DIACONU, Claudia *et al.* The Role of Artificial Intelligence in Monitoring Inflammatory Bowel Disease—The Future Is Now. *Diagnostics*, v. 13, n. 4, p. 735, 2023.

[3] Objective. TinyML: O próximo passo da Inteligência Artificial e do Machine Learning, Objective, 2024. Disponível em: <<https://www.objective.com.br/insights/tinyml/>>. Acessado em Jan 17, 2025.

[4] ZAEEM, Hayder. Best Python Libraries for Machine Learning, Python Developers Community (Linkedin Group), 2025. Disponível em: <https://media.licdn.com/dms/image/v2/D4E22AQHYQ44EAZ58rQ/feedshare-shrink_800/B4EZRk97wMG0Ag-/0/1736860746065?e=1740009600&v=beta&t=h1sDbbDMrwLI9SFPzUHHS_PEDNBZuwhtphePjuoXmO0>. Acessado em Jan 17, 2025.

[5] AWARI. Machine Learning com Python: Guia Completo e Exemplos. Awari Atividades de Ensino, 2024. Disponível em: <<https://awari.com.br/machine-learning-com-python-guia-completo-e-exemplos/>>. Acessado em Jan 17, 2025.

[6] COURSERA STAFF, 9 Best Python Libraries for Machine Learning, Coursera, 2023. Disponível em: <<https://www.coursera.org/articles/python-machine-learning-library>>. Acessado em Jan 17, 2025.

[7] JANAPA REDDI, Vijay *et al.* Edge impulse: An mlops platform for tiny machine learning. *Proceedings of Machine Learning and Systems*, v. 5, 2023. Disponível em: <https://proceedings.mlsys.org/paper_files/paper/2023/file/49fe55f5e9574714dda575bfb2177662-Paper-mlsys2023.pdf>. Acessado em Jan 17, 2025.