



Métricas de Desempenho em Modelos de IA (parte 2)

Por: Dr. Arnaldo de Carvalho Junior

Data: 13/05/2025

1. INTRODUÇÃO

Este *post* continua a tratar métricas de desempenho iniciadas no post anterior [1], onde foram abordadas as métricas de desempenho de modelos de IA para classificação.

Neste *post* serão abordadas as métricas de desempenho de regressão, utilizadas em modelos de IA para aproximação de funções, identificação de sistemas, previsões, entre outras aplicações [2].

Primeiro, segue uma introdução da Regressão Linear/Múltipla Linear.

1.1. Regressão Linear / Múltipla

A Regressão é uma técnica cujo objetivo é prever o valor de uma variável dependente (Y) quando se tem um conjunto de valores que são as variáveis independentes (X). A Regressão Linear é uma das técnicas mais básicas em aprendizado de máquinas (*machine learning* - ML) que se pode utilizar para realizar previsões [3][4].

Uma Equação de Regressão é dada em (1), onde 'E' significa o erro que é introduzido quando o modelo realmente não se encaixa nos dados. O objetivo de um bom modelo de regressão é minimizar esse erro.

$$y = B_0 + B_1x_1 + B_2x_2 + E \quad (1)$$

O erro é dado pela diferença entre o valor real (y) e o valor predito ($\hat{y}$) pelo modelo.

2. MÉTRICAS DE REGRESSÃO

Usadas quando a variável alvo é contínua [5]. Exemplo: preços de casas, previsão de temperatura, valores de estoque, etc. A seguir são apresentadas métricas utilizadas para avaliar modelos de regressão:

a) Raiz do erro quadrático médio (*root mean square error* - **RMSE):** Mede a raiz quadrada das diferenças quadráticas médias entre os valores previstos e reais. Penaliza fortemente grandes erros, tornando-o ideal para modelos onde grandes desvios são críticos.

b) Erro quadrado (*square error* - **SE):** A diferença quadrada bruta entre os valores previstos e reais. Útil para enfatizar erros atípicos.

c) Erro Absoluto Médio (*mean absolute error* - **MAE):** Mede as diferenças absolutas médias entre os valores previstos e reais. Mais fácil de interpretar e menos sensível a outliers em comparação com RMSE.

Essas métricas ajudam a quantificar o desempenho do sistema e orientam a melhoria contínua durante o desenvolvimento e implantação do modelo de IA [5].

A seguir são apresentadas métricas utilizadas para avaliar modelos de regressão, tais como MAE, MAPE, MSE, RMSE, R^2 e R^2 ajustado.

2.1 MAE

O erro médio absoluto (MAE) pode ser calculado conforme a Equação (2). Nesta equação há o cálculo da média da diferença entre o valor predito $\hat{y}$ e o real y . Quanto menor o valor de MAE, significa que melhor são os resultados preditos pelo modelo de ML [6][7].

$$MAE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

O valor de saída da equação tem a mesma escala dos dados utilizados para previsão, tornando mais fácil a sua interpretação. Se o valor de **MAE** resultante for igual a 10,05 m, por exemplo, este resultado significa que o modelo pode estar errando em média 10,05 m

para mais quanto para menos (erro de $\pm 10,05$ m) em relação ao valor correto. Por esta razão que este resultado precisa ser levado em consideração para a tomada de decisão quando analisando previsão futura [6].

Mas o quanto este erro representa em relação ao valor real percentualmente?

2.2. MAPE

O erro percentual absoluto médio (*mean absolute percentual error* - MAPE) é uma métrica que mostra a porcentagem de erro em relação aos valores reais. A Equação (3) apresenta o cálculo de MAPE que é semelhante ao MAE, mas com o acréscimo de uma divisão por $|y|$. Então se o resultado do MAPE for igual a 35% significa que o modelo de IA faz previsões que em média a diferença entre o valor previsto e o real equivale a $\pm 35\%$ do valor real [6].

$$MAPE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)} \quad (3)$$

Ao observar a Equação (3) nota-se que caso o valor de y seja 0, ocorrerá um erro, devido a divisão por zero. Por isso que a biblioteca [scikit-learn](https://scikit-learn.org/) utiliza a tratativa de colocar um número muito pequeno, representado por ϵ , cujo valor é $2,220446049250313e-16$. A métrica MAPE é uma das métricas mais usadas para reportar a performance do modelo de IA, oferecendo uma compreensão mais abrangente do resultado do MAE.

2.3. MSE

O erro quadrático médio (*mean square error* – MSE) nada mais é do que a média dos quadrados da diferença entre os valores observados e previstos. Ele é dado pela Equação (4).

$$MSE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4)$$

Onde n é o número de termos, y_i significa o valor observado para o i -ésimo termo e $\hat{y}_i$ refere-se ao valor previsto para esse termo específico. A diferença é o termo **Erro**. Soma-

se os quadrados de todos os termos de erro e divide-se pelo grau de liberdade (número de variáveis independentes, ou n).

Mas por que ao quadrado? Para que o erro seja acumulado em vez de erros negativos cancelarem erros positivos.

A métrica MSE apresenta um problema de interpretabilidade. Por haver a elevação ao quadrado, a unidade fica distorcida, em outras palavras, se a unidade medida for metros (m), o resultado será em m^2 . Por isso que uma adaptação da MSE é a RMSE que será apresentada a seguir.

2.4. RMSE

RMSE é a raiz do MSE, conforme a Equação (5). O RMSE é basicamente o mesmo cálculo de MSE, contendo ainda a mesma ideia de penalização entre diferenças grandes do valor previsto e o real. No entanto, para lidar com o problema da diferença entre unidades, é aplicada a raiz quadrática. Assim a unidade fica na mesma escala que o dado original, sendo o resultado da métrica melhor interpretável [6].

$$RMSE(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5)$$

Nesta equação há o cálculo da diferença entre o valor y e $\hat{y}$, contudo com a elevação do resultado ao quadrado. Mas para deixar o resultado na mesma escala que os dados, é aplicado a raiz quadrada no resultado. Apesar de o valor ter a mesma unidade, ele não costuma se assemelhar ao resultado encontrado de MAE, demonstrando como os *outliers* podem estar impactando nas previsões do modelo. Mas a sua interpretabilidade pode seguir a mesma lógica, onde o resultado da métrica sendo igual a 70,0 m, significa que o modelo pode estar errando em $\pm 70,0$ m. Por essa razão, esta métrica pode ser uma boa opção quando é preciso ter uma avaliação mais criteriosa sobre as previsões do modelo.

2.5. R^2

O R-quadrado, R-dois ou coeficiente de determinação, é uma medida estatística de quão próximos os dados estão da linha de regressão ajustada. Ele também é conhecido como o coeficiente de determinação ou o coeficiente de determinação múltipla para a regressão múltipla. A definição do R^2 é bastante simples: é a porcentagem da variação da variável resposta que é explicada por um modelo linear [5]. Ou:

$R^2 = \text{Variação explicada} / \text{Variação total}$ (Equação (6))

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

Os valores de y são os valores verdadeiros e o $\bar{y}$ é a média desses valores, enquanto que $\hat{y}$ são os valores preditos. Os resultados de R^2 ficam entre 0 e 1, quanto mais perto de 1 melhor e pior para resultados perto de 0. O R^2 está sempre entre 0 e 100%:

- 0% indica que o modelo não explica nada da variabilidade dos dados de resposta ao redor de sua média.
- 100% indica que o modelo explica toda a variabilidade dos dados de resposta ao redor de sua média.

Em geral, quanto maior o R^2 , melhor o modelo se ajusta aos seus dados. No entanto, existem condições importantes para esta diretriz.

A proporção de variância na variável dependente que é prevista a partir das variáveis independentes. O valor varia de 0 a 1. 1 mostra que a regressão explica perfeitamente a relação. 0 o oposto.

Se A proporção de variância na variável dependente que é prevista a partir das variáveis independentes. O valor varia de 0 a 1. 1 mostra que a regressão explica perfeitamente a relação. 0 o oposto.

Se R^2 (Leia como *R-quadrado*)= 0,45 para a equação (1) de regressão do item 1.2, então significa que 45% da variabilidade em y é explicado pelas variáveis x_1 e x_2 .

No entanto há uma falha. À medida que o número de termos aumenta, o R^2 pode permanecer constante ou aumentar. Isso acontece mesmo que não haja uma boa relação entre as variáveis e a variável dependente [5]. Assim sendo, utilizando somente a métrica R^2 , será que um valor de 0,5 já seria o suficiente para colocar o modelo em produção? Faz-se necessário aproximar ainda mais o seu resultado para 1? Para responder a essas questões, recomenda-se sempre utilizar outras métricas para uma análise mais completa sobre a performance do modelo de IA [6].

Depois de elevá-lo ao quadrado, é necessário reduzir a escala para as unidades originais.

2.4. R^2 Ajustado

R^2 Ajustado é um refinamento sofisticado da métrica R^2 convencional, sendo uma ferramenta poderosa no escopo da avaliação de modelos. À medida que novos preditores são introduzidos, o R^2 Ajustado adapta-se dinamicamente, ascendente ou descendente, com base na medida em que estes preditores melhoram o desempenho do modelo. Este ajuste perspicaz transcende as limitações do R^2 convencional, que captura apenas a proporção de variância explicada pela variável independente(s). Um valor ajustado que considerará a relação entre as variáveis. Diminuirá o valor para variáveis que não melhoram o modelo existente. A fórmula para o R^2 ajustado é dada pela Equação (7) [8].

$$Adjusted R^2 = 1 - \frac{(1 - R^2)(N - 1)}{N - p - 1} \quad (7)$$

Onde N é dado pelo número de registros em um *dataset* e p o número de variáveis independentes.

Em total contraste com o R^2 convencional, que permanece indiferente ao número de preditores utilizados, o R^2 ajustado aparece como um avaliador perspicaz e sensato, penalizando profundamente a inclusão de características irrelevantes ou redundantes que

não têm impacto significativo na previsão da variável alvo. Esta métrica astuta considera cuidadosamente a contagem de variáveis independentes implementadas no processo de previsão, abrindo caminho para uma avaliação mais abrangente e equitativa das proezas preditivas do modelo.

Ao ajustar seu valor com base no número de preditores, o R^2 ajustado eleva o processo de avaliação do modelo para um escalão superior, orientar os pesquisadores para a seleção dos preditores mais influentes e pertinentes, ao mesmo tempo que desencoraja a incorporação de variáveis supérfluas. Este ajuste refinado equipa os cientistas de dados com uma ferramenta poderosa e informada, mantendo a curadoria de modelos mais parcimoniosos que atingem um equilíbrio ideal entre precisão preditiva e parcimônia.

De tudo isso, deve ter tido agora alguma ideia sobre como os modelos podem ser comparados em uma regressão.

3. RESUMO

Com base no apresentado até aqui a Tabela 1 a seguir aponta as principais diferenças entre as métricas de avaliação de regressão MSE, RMSE, MAE, MAPE, R^2 e R^2 ajustado [9].

Tabela 1
Comparação entre Métricas de Regressão MSE, RMSE, MAE, MAPE, R^2 e R^2 ajustado [9]

Métricas	O que?	Por quê?	Quando Usar?
MSE	Mede a diferença quadrática média entre os valores estimados e reais.	Enfatiza erros maiores.	Quando erros grandes são mais críticos.
RMSE	Raiz quadrada do MSE, nas mesmas unidades da variável resposta.	Interpretação mais fácil dos erros.	Quando a escala de erro deve corresponder à escala alvo.
MAE	Diferença absoluta média entre os valores estimados e reais.	Menos sensível a outliers.	Com muitos valores discrepantes ou resíduos não normais.
MAPE	Erro percentual entre valores estimados e reais.	Fácil interpretação como porcentagem.	Para previsão e análise de erros baseada em porcentagem.
R^2	Proporção de variância explicada pelo modelo.	Indica o poder explicativo do modelo.	Avaliar modelos de regressão linear' fit.
R^2 Ajustado	Medida estatística que modifica o valor R^2 para contabilizar o número de preditores	Ao contrário do R^2 , penaliza o modelo por incluir preditores irrelevantes	Útil em cenários de regressão múltipla onde você tem várias variáveis independentes

4. CONCLUSÃO

Neste *post* foram apresentadas algumas das métricas mais utilizadas para avaliar o modelos de regressão acompanhado de suas particularidades.

Como visto a métrica a ser adotada depende da solução que o modelo pode vir a resolver com o modelo de ML. Uma abordagem comum, fácil de ser implementada e muito interessante é utilizar todas para se ter diferentes perspectivas em relação a performance do modelo.

Dentre as métricas apresentadas, o R^2 é uma métrica muito comum, mas difícil de ser utilizada sozinha para se tirar conclusões completas sobre a performance do modelo. O R^2 ajustado é um resultado muito importante para saber se o conjunto de dados é adequado ou não. Alguém faz uma equação de regressão para validar se o que pensa sobre a relação entre duas variáveis é também validado pela equação de regressão. Quanto maior for o R^2 ajustado, melhor é a equação de regressão, uma vez que implica que a variável independente escolhida para determinar a variável dependente seja corretamente escolhida. Idealmente, um investigador procurará o coeficiente de determinação mais próximo dos 100%.

Tanto MAE e MAPE apresentam uma boa interpretabilidade, principalmente para relatório dos resultados do modelo. Já as métricas MSE e RMSE são afetadas por valores discrepantes, o que pode ser importante quando é preciso ter uma avaliação mais criteriosa do modelo de ML.

5. REFERÊNCIAS

- [1] CARVALHO JUNIOR, A. Métricas de Desempenho em Modelos de IA (parte 1), EAILAB, IFSP, 2025. Disponível em: [https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2012%20-%20Métricas%20de%20Desempenho%20em%20Modelos%20de%20IA%20\(parte%201\).pdf](https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2012%20-%20Métricas%20de%20Desempenho%20em%20Modelos%20de%20IA%20(parte%201).pdf). Acessado em Mai 10, 2025.
- [2] CARVALHO, A., JUSTO, J.F., ANGÉLICO B.A. *et al.* Model reference control by recurrent neural network built with paraconsistent neurons for trajectory tracking of a rotary inverted pendulum, *Applied Soft Computing*, 2022, 109927, ISSN 1568-4946, DOI: [10.1016/j.asoc.2022.109927](https://doi.org/10.1016/j.asoc.2022.109927).
- [3] KAKANADAN, U. Regression and performance metrics — Accuracy, precision, RMSE and what not!, Medium, 2024. Disponível em: <https://medium.com/analytics-vidhya/regression-and-performance-metrics-accuracy-precision-rmse-and-what-not-223348cfcafe>. Acessado em Jul 31, 2024.
- [4] AMORIM, N. Regressão Linear Simples com Python e sklearn, Dev 4.0, 2021. Disponível em: <https://dev4lab.github.io/posts/regressao-lienar-com-python/#:~:text=Regressão%20Linear%20C3%A9%20uma%20das%20t%C3%A9cnicas>. Acesso em Mai 12, 2025.
- [5] DILMEGANI, C. How To Measure AI Performance, AI Multiple Research, 2025. Disponível em: <https://research.aimultiple.com/how-to-measure-ai-performance/>. Acessado em Mai 05, 2025.
- [6] MINITAB, Análise de regressão: Como interpretar o R-quadrado e avaliar a qualidade de ajuste?, Blog do Editor, Minitab, 2019. Disponível em: <https://blog.minitab.com/pt/analise-de-regressao-como-interpretar-o-r-quadrado-e-avaliar-a-qualidade-de-ajuste>. Acessado em Mai 06, 2025.
- [7] OLIVEIRA JUNIOR, C. Métricas para Regressão: Entendendo as métricas R², MAE, MAPE, MSE e RMSE, Medium, 2021. Disponível em: <https://medium.com/data-hackers/prevendo-números-entendendo-métricas-de-regressão-35545e011e70>. Acesso em Mai 12, 2025.

[8] RAJESH, P. S. What is Adjusted R-Squared, Net-Information.com, 2024. Disponível em: <https://net-informations.com/ds/psa/adjusted.htm>. Acesso em Mai 13, 2025.

[9] KUMAR, A. MSE vs RMSE vs MAE vs MAPE vs R-Squared: When to use?, Analytics logue, 2024. Disponível em: <https://vitalflux.com/mse-vs-rmse-vs-mae-vs-mape-vs-r-squared-when-to-use/>. Acesso em Mai 13, 2025.