

Transformers: A Arquitetura Que Revolucionou a IA Contemporânea

Por: Dr. Arnaldo de Carvalho Junior

Data: 25/05/2026.

1. Introdução

Na área de processamento de linguagem natural – PLN (*Natural Language Processing* - NLP), a grande ruptura no desenvolvimento da inteligência artificial (IA) ocorreu com a arquitetura de aprendizado profundo (*Deep Learning* - DL), chamada transformador (*Transformer*). Essa arquitetura foi proposta por pesquisadores do Google, até de forma modesta, em um artigo “*preprint*” de 2017, chamado “Attention is all you need!” [1].

As redes *Transformers* permitiram o surgimento dos Modelos de Linguagem de Grande Escala (*Large language Models* - LLMs), capazes de gerar textos coerentes, responder perguntas, resumir documentos e auxiliar na programação.

Os LLMs operam prevendo a próxima palavra mais provável em um contexto, o que explica tanto seu poder quanto suas limitações. Isso permitiu a construção de arquiteturas complexas de IA Generativa que se vê hoje, capaz de criar conteúdo (texto, códigos, áudios, vídeos, ...) e até atendentes autônomos orientados a objetivos, chamados IA Agencial ou Agentica (*Agentic AI*) [2].

2. Redes *Transformer*: uma explicação simples

As **redes Transformer** são uma arquitetura de redes neurais desenvolvida para lidar de forma eficiente com **dados sequenciais**, como textos, sinais e códigos. Eles introduzem uma mudança de paradigma ao eliminar a recorrência e utilizar **mecanismos de atenção**.

Diferentemente de arquiteturas mais antigas, como redes neurais recorrentes (*Recurrent Neural Networks* - RNNs), os Transformers **processam todos os elementos da sequência em paralelo**, o que torna o treinamento mais rápido e escalável. Essa

mudança explica o por que os Transformes se tornaram a espinha dorsal da IA Generativa contemporânea [3].

2.1. Principais blocos de uma rede *Transformer*

A Figura 1 apresenta a arquitetura de uma rede *Transformer* [1]. Ela é formada por blocos empilhados, que se repetem ao longo da arquitetura.




Figura 1 – Arquitetura do Transformer
Fonte: Adaptado de [1].

Os principais componentes são [4]:

1. **Camada de *Embedding***: Cada palavra, símbolo ou unidade de entrada é convertida em um vetor numérico contínuo, chamado *embedding*, que representa seu significado de forma matemática.
2. **Codificação Posicional (*Positional Encoding*)**: Como o *Transformer* não possui memória sequencial explícita, ele adiciona informações sobre a **posição dos tokens** na sequência, permitindo distinguir, por exemplo, o início e o fim de uma frase.
3. **Mecanismo de Atenção (*Self-Attention*)**: Esse é o núcleo do *Transformer*. Ele permite que cada *token* “preste atenção” a outros *tokens* da sequência, atribuindo

pesos diferentes conforme a relevância contextual. Assim, o modelo consegue capturar relações de longo alcance em um texto.

4. **Atenção Multi-Cabeça (Multi-Head Attention):** Em vez de uma única atenção, o modelo utiliza várias atenções em paralelo, permitindo capturar diferentes tipos de relações semânticas e sintáticas ao mesmo tempo.
5. **Redes Feedforward:** Após a atenção, cada **token** passa por uma pequena rede neural totalmente conectada, que transforma os vetores e aumenta a capacidade de representação do modelo.
6. **Normalização e Conexões Residuais:** Esses mecanismos ajudam a estabilizar o treinamento e permitem que a informação flua melhor pelas camadas profundas da rede.
7. **Saída Camada Densa Linear + Softmax:** A camada de rede neural densa linear possui o tamanho do vocabulário. Logo após, a função Softmax (ou função exponencial normalizada) é aplicada, gerando a distribuição de probabilidades de cada uma das palavras.

2.2 O que é um *token* para os *Transformers*?

Um **token** é a unidade básica de processamento usada pelos *Transformers*. Dependendo do modelo, um *token* pode representar uma palavra inteira, parte de uma palavra (subpalavra), um caractere ou até símbolos especiais [5].

Por exemplo, a palavra “aprendizado” pode ser dividida em vários *tokens* menores. O modelo não “entende” palavras diretamente, mas sim **sequências de tokens representadas por números**.

Esses tokens são então transformados em incorporações (**embeddings**) e processados pelo mecanismo de atenção, permitindo ao modelo aprender padrões linguísticos, semânticos e contextuais.

Nota: Embora os *Transformers* sejam extremamente eficazes em tarefas de linguagem e geração de conteúdo, eles **não possuem compreensão ou consciência**, operando exclusivamente por meio de **padrões estatísticos** aprendidos a partir de grandes **volumes de dados**.

Um tutorial de uso e exemplo de Rede *Transformer* em Python está disponível respectivamente nas referências [5] e [6]. Este exemplo pode ser executado diretamente

via a plataforma Google Colab. Note o tempo que leva para executar o treinamento do Transformer neste exemplo.

3. Características dos *Transformers*

A Tabela 1 apresenta as características principais dos *Transformers*.

Tabela 1 – Características dos *Transformers*.

Dimensão	Descrição
Arquitetura	Baseada em atenção (Self-Attention), sem recorrência ou convolução
Processamento	Paralelo sobre toda a sequência de tokens
Unidade Básica	Token (palavra, subpalavra ou símbolo)
Blocos Principais	Embedding + Positional Encoding, Multi-Head Attention, Feed-Forward Networks, Normalização e Conexões residuais
Memória Contextual	Global — cada token pode atender a todos os outros
Escalabilidade	Alta, especialmente em GPUs/TPUs
Aplicações Típicas	LLMs, tradução, sumarização, chatbots, visão multimodal

4. *Transformers*: usar ou não usar?

Apesar de revolucionária, nem sempre os *Transformers* são a melhor tecnologia a ser aplicada. As Tabelas 2 e 3 apresentam respectivamente as vantagens e desvantagens desta tecnologia revolucionária.

Tabela 2 – Vantagens de se usar os *Transformers*.

Vantagem	Impacto Prático
Captura eficiente de dependências longas	Melhor compreensão de contexto em textos extensos
Processamento altamente paralelizável	Treinamento mais rápido em grande escala
Excelente desempenho em PLN e IA Generativa	Base de modelos como GPT, BERT, T5, LLaMA
Arquitetura modular e flexível	Fácil adaptação para texto, imagem, áudio e código
Aprendizado contextual profundo	Maior qualidade em tarefas de geração e compreensão

Tabela 3 – Desvantagens de se usar os *Transformers*.

Desvantagem	Implicação
Custo computacional elevado	Exige infraestrutura robusta (GPU/TPU)
Complexidade quadrática da atenção	Limitações para sequências muito longas
Alto consumo de memória	Dificulta uso em dispositivos embarcados
Pouca interpretabilidade	Decisões difíceis de explicar (black box)
Dependência de grandes volumes de dados	Menor eficiência em cenários com poucos dados

4.1. Use *Transformers* quando...

- ✓ O problema envolve sequências complexas
 - Texto longo, documentos, código-fonte, séries multimodais.
 - Ex.: *chatbots*, análise jurídica, sumarização de relatórios, tradução automática.
- ✓ O contexto global é relevante
 - Relações entre elementos distantes da sequência são importantes.
 - Ex.: interpretação semântica, raciocínio contextual, PLN.
- ✓ Há disponibilidade de dados em grande escala
 - Grandes volumes de dados rotulados ou não rotulados.
 - Ex.: treinamento ou ajuste fino (*fine-tuning*) de LLMs.
- ✓ Existe infraestrutura computacional adequada
 - GPUs/TPUs, ambientes em nuvem ou *clusters*.
 - Ex.: empresas, universidades, centros de pesquisa.
- ✓ O objetivo envolve geração de conteúdo
 - Texto, imagem, código, áudio ou múltiplas modalidades.
 - Ex.: IA Generativa, assistentes virtuais, recomendação contextual.

4.2. Evite os *Transformers* quando...

- ✗ O problema é simples ou bem estruturado
 - Relações diretas entre entrada e saída.
 - Ex.: regressão linear, classificação tabular simples.
- ✗ Os dados são escassos
 - Poucos exemplos disponíveis para treinamento.
 - Ex.: pequenos *datasets* industriais ou clínicos.
- ✗ Há restrições severas de recursos
 - Sistemas embarcados, computação de borda (*edge computing*), Internet das Coisas (*Internet of Things* - IoT).

- Ex.: sensores, dispositivos móveis de baixo consumo.
- ✖ A interpretabilidade é requisito central
 - Ambientes regulados ou críticos.
 - Ex.: decisões médicas, jurídicas ou financeiras explicáveis.
- ✖ A latência precisa ser mínima
 - Respostas em tempo real com custo computacional reduzido.
 - Ex.: controle industrial em tempo real.

A Tabela 4 traz aplicações mais indicadas para os *Transformers* e outros modelos de IA [7][8][9].

Tabela 4 – Aplicações e Modelos de IA mais indicados.

Cenário	Modelo mais indicado
Texto, linguagem, multimodal	Transformers
Dados tabulares estruturados	Árvores, regressão, XGBoost
Séries temporais simples	RNNs simples, ARIMA
Edge computing	CNNs leves, modelos clássicos
Alta exigência de explicabilidade	Modelos simbólicos ou estatísticos

5. Considerações Finais

Os *Transformers* são de fato um ponto de virada de chave e o propulsor para a revolução da IA contemporânea. Os *Transformers* oferecem desempenho superior e escalabilidade, porém com o custo de maior complexidade computacional e desafios de interpretabilidade. Assim o uso do *Transformer* deve ser estrategicamente avaliado conforme o contexto, recursos disponíveis e objetivos a serem atingidos.

Referências

- [1] VASWANI, Ashish et al. Attention is all you need. In Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17, 6000–6010. Red Hook, NY, USA: Curran Associates Inc. ISBN 9781510860964.
- [2] CARVALHO JUNIOR, Arnaldo De. Evolução da IA Tradicional para a IA Generativa e Agencial. EAILab, Labmax, IFSP, 2026. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%2014%20-%20Evolução%20da%20IA%20Tradicional%20para%20Generativa%20e%20Agencial.pdf. Acesso em: Fevereiro 05, 2026.
- [3] DEEP LEARNING BOOK. Capítulo 85 – Transformadores – O Estado da Arte em Processamento de Linguagem Natural, Data Science Academy, 2025. Disponível em:

<https://www.deeplearningbook.com.br/transformadores-o-estado-da-arte-em-processamento-de-linguagem-natural/>. Acesso em: Fevereiro 05, 2026.

[4] DE PAIVA, Eduardo Soares; PEREIRA, Fernando Sola. Capítulo 2 - Deep learning para processamento de linguagem natural, Tópicos Especiais em Sistemas de Informação, Minicursos SBSI, Sociedade Brasileira da Computação, 2022. Disponível em: <https://books-sol.sbc.org.br/index.php/sbc/catalog/view/86/379/654>. Acesso em: Fevereiro 05, 2026.

[5] CARVALHO JUNIOR, Arnaldo De. Arquitetura dos Transformadores. EIALab-IFSP, Repositório GitHub, 2025. Disponível em: https://github.com/EAILAB-IFSP/AI_ALGORITHMS/blob/AI_Algorithms/Arquitetura%20dos%20Transformadores.pdf. Acesso em: Fevereiro 05, 2026.

[6] CARVALHO JUNIOR, Arnaldo De. Transformer Using Pytorch. EAILab-IFSP, 2025. Disponível em: <https://colab.research.google.com/drive/13IkORfUEtOwmMC4idP1g-CukSXIgqEds?usp=sharing>. Acesso em: Fevereiro 05, 2026.

[7] CARVALHO JUNIOR, Arnaldo De. Principais Algoritmos Utilizados em Inteligência Artificial, EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%208%20-%20Principais%20Algoritmos%20de%20IA.pdf. Acesso em: Maio 25, 2026.

[8] CARVALHO JUNIOR, Arnaldo De. Redes Neurais Artificiais: Algoritmos poderosos para aplicações de IA e ML. EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%205%20-%20RNAs.pdf. Acesso em: Maio 25, 2026.

[9] CARVALHO JUNIOR, Arnaldo De. O Poder Das CNNs Em Aplicações de ML Envolvendo Identificação e Classificação de Imagens. EAILAB, IFSP, 2024. Disponível em: https://github.com/Arnaldo-Carvalho/EAILab_Posts/blob/main/Post%209%20-%20O%20Poder%20das%20CNNs%20em%20ML.pdf. Acesso em: Maio 25, 2026.