

PROBABILIDADE APLICADA À IA

Editado por: Dr. Arnaldo de Carvalho Junior (com auxílio do ChatGPT)

Data: Junho 10, 2026

INTRODUÇÃO

O objetivo deste *post* não é aprofundar na matemática de cada modelo de probabilidade utilizado em inteligência artificial (IA), mas entender quando eles fazem sentido e onde podem ser aplicados em problemas de negócio [1].

Em muitos problemas reais, não há respostas absolutas, apenas trabalha-se com chances, padrões, riscos e previsões [1].

MODELOS DE PROBABILIDADE UTILIZADOS EM IA

Modelos de probabilidade que ajudam sistemas de IA a transformar incerteza em decisões mais confiáveis [1]. Os nove modelos que utilizam ferramentas de probabilidade para fazer melhores previsões e tomada de decisões são:

1. **Naive Bayes:** O Naive Bayes é um algoritmo de aprendizado de máquina (*machine learning* - ML) utilizado para classificação de dados, baseado no conceito matemático conhecido como Teorema de Bayes. Ele recebe o nome “*naive*” (ingênuo) porque assume que todas as características analisadas são independentes entre si, algo que nem sempre ocorre na prática. Mesmo com essa simplificação, o método costuma apresentar bons resultados em tarefas como filtragem de *spam*, análise de sentimentos e categorização de documentos. De forma simples, o *Naive Bayes* calcula a probabilidade de uma informação pertencer a determinada categoria com base em evidências observadas, escolhendo aquela que apresenta a maior probabilidade de ocorrência. Vide Figura 1a [2],[3].
2. **Regressão Logística:** técnica estatística e de ML utilizada para prever a probabilidade de ocorrência de um evento que possui apenas dois resultados

possíveis, como “sim” ou “não”, “aprovado” ou “reprovado”, “cliente compra” ou “cliente não compra”. Diferentemente da regressão linear, que estima valores numéricos, a regressão logística calcula a chance de determinado resultado acontecer com base em uma ou mais variáveis explicativas, permitindo apoiar decisões e classificações em diversas áreas, como saúde, marketing, finanças e ciência de dados. Por exemplo, um banco pode utilizá-la para estimar a probabilidade de um cliente pagar ou não um empréstimo, considerando fatores como renda, idade e histórico financeiro. Vide Figura 1b [1],[4].

3. **Árvore de Decisão (*Decision Tree*):** Algoritmo de ML que organiza informações em uma estrutura semelhante a uma árvore, na qual cada ramo representa uma pergunta ou condição e cada folha representa uma decisão ou resultado final. Seu funcionamento é intuitivo, pois imita o processo de tomada de decisão humana por meio de perguntas sequenciais, como “a renda é maior que determinado valor?” ou “o cliente possui histórico de inadimplência?”. A partir dessas respostas, o algoritmo segue diferentes caminhos até chegar a uma classificação ou previsão. Por sua facilidade de interpretação e visualização, as árvores de decisão são amplamente utilizadas em áreas como finanças, saúde, marketing e análise de risco. Vide Figura 1c [1],[3].
4. **Vizinhos k-Próximos (*k-Nearest Neighbors – kNN*):** Algoritmo de ML que toma decisões com base na semelhança entre os dados. Seu funcionamento pode ser comparado à ideia de que “objetos parecidos tendem a pertencer ao mesmo grupo”. Quando um novo dado precisa ser classificado, o algoritmo procura os k exemplos mais próximos dele em um conjunto de dados já conhecido e verifica qual categoria aparece com maior frequência entre esses vizinhos. Por exemplo, para identificar se um e-mail é spam, o k-NN compara suas características com mensagens já classificadas e atribui a categoria predominante entre os exemplos mais semelhantes. Por sua simplicidade e eficiência em diversos problemas de classificação e previsão, o k-NN é amplamente utilizado em aplicações de mineração de dados e IA. Vide Figura 2a [1],[5].




Figura 1: Modelos Estatísticos utilizados em IA – Naive Bayes (a), Regressão Logística (b), Árvore de Decisão (Decision Tree) (c).

- 5. Floresta Aleatória (Random Forest - RF):** Algoritmo de ML que combina várias **árvores de decisão** para produzir resultados mais precisos e confiáveis. Em vez de depender de uma única árvore, o método cria diversas árvores utilizando diferentes amostras dos dados e, ao final, reúne as respostas de todas elas para tomar uma decisão, geralmente por votação. Essa estratégia reduz a influência de erros individuais e melhora a capacidade de generalização do modelo. De forma simples, é como consultar vários especialistas sobre um mesmo problema e considerar a opinião da maioria para chegar a uma conclusão mais segura. Por sua robustez e bom desempenho, o **Random Forest** é amplamente utilizado em áreas como finanças, saúde, marketing e detecção de fraudes. Vide Figura 2b [1],[6].
- 6. Aumento de Gradiente (Gradient Boosting):** Técnica de ML que combina várias **árvores de decisão simples** para criar um modelo mais preciso e eficiente. O método funciona de forma sequencial: cada nova árvore é treinada para corrigir os erros cometidos pelas árvores anteriores, melhorando gradualmente a qualidade das previsões. Essa abordagem é muito utilizada em problemas de classificação e regressão, sendo reconhecida por seu alto desempenho em tarefas como previsão de vendas, análise de risco, detecção de fraudes e recomendação de produtos. Vide Figura 2c [1],[7].




Figura 2: Modelos Estatísticos utilizados em IA – Vizinhos k -próximos (*k-Nearest Neighbors* - kNN) (a), Floresta Aleatória (*Random Forest*) (b), Aumento de Gradiente (*Gradient Boosting*) (c).

- 7. Modelo de Mistura Gaussiana (Gaussian Mixture Model – GMM):** Técnica de ML usada para identificar grupos em um conjunto de dados. Diferentemente de métodos que atribuem cada elemento a um único grupo, o GMM considera que um dado pode pertencer a diferentes grupos com determinadas probabilidades. Ele assume que os dados são gerados por uma combinação de várias distribuições gaussianas (curvas em forma de sino), permitindo modelar conjuntos de dados mais complexos e com formatos variados. Essa técnica é amplamente utilizada em segmentação de clientes, reconhecimento de padrões, processamento de imagens e detecção de anomalias. Vide Figura 3a [1],[8].
- 8. Cadeias de Markov:** São modelos matemáticos usados em IA para prever eventos futuros com base apenas na situação atual, sem considerar todo o histórico anterior. Em termos simples, elas funcionam como um sistema de probabilidades que estima qual será o próximo passo a partir do estado presente. Essa abordagem é aplicada em diversas áreas da IA, como reconhecimento de fala, processamento de linguagem natural, sistemas de recomendação e análise de comportamento, ajudando computadores a tomar decisões e fazer previsões em ambientes incertos. Vide Figura 3b [1],[9].

9. **Modelo Oculto de Markov (Hidden Markov Model – HMM):** Técnica de IA utilizada para analisar sequências de eventos quando os estados reais do sistema não podem ser observados diretamente. Em vez disso, o modelo utiliza informações visíveis para inferir o que provavelmente está acontecendo “nos bastidores”. Uma analogia simples seria tentar descobrir o clima de um dia observando apenas as roupas que as pessoas usam. Os HMMs foram amplamente empregados em reconhecimento de fala, processamento de linguagem natural, bioinformática e sistemas de detecção de padrões, permitindo que computadores façam previsões e interpretações em situações de incerteza. Vide Figura 3c [1],[10].




Figura 3: Modelos Estatísticos utilizados em IA – Modelo de Mistura Gaussiana (*Gaussian Mixture Model* - GMM) (a), Cadeias de Markov (b), Modelo Oculto de Markov (*Hidden Markov Model* - HMM) (c).

CONCLUSÃO

A análise dos nove modelos de probabilidade apresentados neste *post* — Naive Bayes, Regressão Logística, Árvore de Decisão, k-NN, *Random Forest*, *Gradient Boosting*, GMM, Cadeias de Markov e HMM — demonstra a diversidade de abordagens disponíveis para previsão e tomada de decisão em sistemas de IA.

Cada modelo apresenta características específicas que o tornam mais adequado para determinados tipos de problemas, desde tarefas de classificação e previsão até reconhecimento de padrões e análise de sequências temporais.

Enquanto métodos como *Naive Bayes* e Regressão Logística oferecem simplicidade, interpretabilidade e eficiência computacional, técnicas como *Random Forest* e *Gradient Boosting* proporcionam maior poder preditivo ao combinar múltiplos modelos. Por sua vez, o GMM destaca-se na identificação de agrupamentos probabilísticos em dados complexos, enquanto as Cadeias de Markov e os HMMs são especialmente úteis para modelar processos dinâmicos e eventos que evoluem ao longo do tempo.

Em conjunto, esses modelos evidenciam que não existe uma única solução ideal para todos os cenários de IA. A escolha do método mais adequado depende da natureza dos dados, dos objetivos da aplicação, dos requisitos de precisão e da necessidade de interpretação dos resultados. Dessa forma, o conhecimento das características, vantagens e limitações de cada abordagem é fundamental para o desenvolvimento de sistemas inteligentes mais robustos, confiáveis e capazes de apoiar a tomada de decisão baseada em evidências e probabilidades.

REFERÊNCIAS

- [1] BENEDICTO, Marcos De. 9 Modelos Que Utilizam Probabilidade Para Fazer Melhores Previsões e Tomada de Decisões, LinkedIn Post, 2026. Disponível em: https://media.licdn.com/dms/image/v2/D4D22AQEUUVUkIEu3Skw/feedshare-shrink_800/B4DZ6JdRUJl4BU-/0/1780422612539?e=1782950400&v=beta&t=4mEYFj3ioMj_X2n0LWjq3Y0TOCzgSDNI96QkUIXvfk. Acesso em: Junho 10, 2026.
- [2] WIKIPEDIA CONTRIBUTORS, "Naive Bayes classifier," Wikipedia, The Free Encyclopedia, https://en.wikipedia.org/w/index.php?title=Naive_Bayes_classifier&oldid=1355160729, Acesso em: Junho 10, 2026.
- [3] FRANK, Eibe; HALL, Mark A. Data mining: practical machine learning tools and techniques. Morgan Kaufmann, 2011.
- [4] JAMES, Gareth et al. An introduction to statistical learning: with applications in R. New York: springer, 2013.
- [5] TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. Introduction to data mining. Pearson Education India, 2016.
- [6] HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2. ed. New York: Springer, 2009.

- [7] FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. *Annals of statistics*, p. 1189-1232, 2001.
- [8] BISHOP, Christopher M.; NASRABADI, Nasser M. *Pattern recognition and machine learning*. New York: springer, 2006.
- [9] SUTTON, Richard S. et al. *Reinforcement learning: An introduction*. Cambridge: MIT press, 2nd edition, 2018. ISBN: 978-0-262-03924-6.
- [10] RABINER, Lawrence R. A tutorial on hidden Markov models and selected applications in speech recognition. *Proceedings of the IEEE*, v. 77, n. 2, p. 257-286, 1989. DOI:10.1109/5.18626.